

Entwicklung und psychometrische Prüfung der GEB-12

Eine Kurzform der General Ecological Behavior Scale (GEB-50)

Jaromir Gerhardt, Luisa Hautzinger, Theresa Knoch, Jako Spretz

2026-06-30

1 Einleitung

1.1 Die Langform: GEB-50

Die *General Ecological Behavior Scale* (GEB-50) von Kaiser (2020) misst die individuelle Umwelteinstellung über selbstberichtetes ökologisches Verhalten. Theoretische Grundlage ist das **Campbell-Paradigma**: Eine Einstellung zeigt sich in den Verhaltenskosten, die eine Person bereit ist zu tragen, um ein Einstellungsziel zu erreichen. Je kostenintensiver ein Verhalten (z. B. der Verzicht auf ein Auto gegenüber dem Trennen von Altglas), desto stärker die zugrunde liegende Umwelteinstellung.

Die GEB-50 umfasst 50 Items aus **sechs Handlungsbereichen** – Energiesparen, Mobilität, Abfallvermeiden, Konsum, Recycling und gesellschaftliches Engagement. Sie wird über ein **eindimensionales Rasch-Modell** ausgewertet, sodass Personen- und Itemparameter auf einer gemeinsamen latenten Dimension liegen und keine Normierung erforderlich ist (Kaiser, 2020). Die Vollversion erreicht eine Separationsreliabilität von $rel = .71$ bis $.88$ (Kaiser, 2020). Belege zur Konstrukt- und Kriteriumsvalidität liegen vor: So korreliert die GEB-50 mit der konstruktnahen NEP-Skala (*New Ecological Paradigm*) zu $r = .49$; die prognostische Validität wurde u. a. in einer Untersuchung mit Autofahrer:innen nachgewiesen (Kaiser, 2020).

1.2 Motivation für eine Kurzform

In vielen Anwendungskontexten – Interventionsstudien, wiederholte Messungen, Online-Erhebungen mit knappem Zeitbudget – ist eine 50-Item-Skala unökonomisch. Eine validierte **12-Item-Kurzform (GEB-12)** würde die Erhebungsdauer deutlich senken und gleichzeitig die zentrale Eigenschaft der Langform – die Messung einer einzelnen latenten Umwelteinstellung – erhalten.

Eine Kurzform ist jedoch nicht einfach eine beliebige Item-Teilmenge. Smith et al. (2000) warnen ausdrücklich vor „Sünden“ der Kurzformentwicklung: Eine Kurzform muss eigenständig auf Reliabilität, faktorielle Struktur und Konstruktvalidität gegenüber der Langform geprüft werden. Genau dieser Prüfung folgt der vorliegende Bericht.

2 Methoden

2.1 Konstruktion der Kurzform

Die Itemauswahl folgt einem theoriegeleiteten Verfahren in Anlehnung an Smith et al. (2000) und die Konstruktionslogik der Langform (Kaiser, 2020):

1. **Inhaltsvalidität**: Alle sechs Handlungsbereiche bleiben vertreten – je **ein leichtes** (geringe Verhaltenskosten) und **ein schweres** Item (hohe Verhaltenskosten) pro Bereich. Das ergibt $6 \times 2 = 12$ Items und sichert die inhaltliche Breite des Konstrukts.

Tabelle 1: Itemauswahl der GEB-12 (je Bereich ein leichtes und ein schweres Item)

```
# A tibble: 6 x 3
  Bereich      `Leichtes Item (geringe Kosten)` Schweres Item (hohe ~1
  <chr>      <chr>                                <chr>
1 (1) Energiesparen Ich warte, bis ich eine volle Wäsc~ Ich beziehe Strom aus~
2 (2) Mobilität    Für den Arbeits-/Schulweg nutze ic~ Ich verzichte auf ein~
3 (3) Abfallvermeiden Wenn ich im Geschäft eine Plastikt~ Ich verwende Einkaufs~
4 (4) Konsum       Ich benutze beim Waschen einen Wei~ Ich kaufe Obst und Ge~
5 (5) Recycling    Altglas bringe ich zum Sammelconta~ Leere Batterien werfe~
6 (6) Ges. Engagement Ich unterhalte mich mit Bekannten ~ Ich boykottiere Produ~
# i abbreviated name: 1: `Schweres Item (hohe Kosten)`
```

2. **Schwierigkeitsverteilung:** Durch das Paar leicht/schwer wird der gesamte Bereich der Verhaltenskosten abgedeckt; Decken- und Bodeneffekte sollen vermieden werden (Ziel-Schwierigkeiten $P = .20$ bis $.80$).
3. **Trennschärfe:** Bevorzugt werden Items mit hoher Item-Total-Korrelation ($r_{it} > .40$).
4. **Rasch-Konformität:** Items sollen die Raschhomogenität der Langform erhalten.

Die resultierende Itemauswahl (zwei Items je Bereich) ist in Tabelle 1 dargestellt.

i Antwortformat und Kodierung

Wie in der Langform werden Häufigkeitsantworten (Hfg.) **dichotomisiert**: *oft* / *sehr oft* → 1, *nie* / *selten* / *gelegentlich* → 0 (Kaiser, 2020). Negativ formulierte Items werden vor der Analyse umgepolt, ja/nein-Items direkt übernommen. Die 12 Items mischen Häufigkeits- und Ja/Nein-Format (gemischtes Modell).

2.2 Pretest: Funktion und statistische Einordnung

Vor der Hauptuntersuchung wurde ein **Pretest mit $N = 6$ Personen** durchgeführt. Seine Funktion war ausschließlich die Prüfung von **Verständlichkeit und Durchführbarkeit** des Fragebogens, nicht die Itemqualität. Bei dieser Fallzahl sind Trennschärfen, Itemschwierigkeiten und Rasch-Parameter zu instabil für verlässliche Entscheidungen; ein Itemaustausch auf dieser Basis hätte die theoriegeleitete, balancierte Auswahl (je Bereich ein leichtes und ein schweres Item) ohne echten Erkenntnisgewinn gefährdet. Da die Items zudem bereits aus der rasch-skalierten, validierten Langform stammen und nach inhaltlichen sowie psychometrischen Kriterien (Smith et al., 2000) ausgewählt wurden, war eine empirische Vorab-Filterung an dieser Mini-Stichprobe nicht erforderlich.

Die Pretest-Ergebnisse dienten daher **nur** der Sicherstellung von Verständlichkeit und Durchführbarkeit. Alle berichteten psychometrischen Prüfungen beruhen ausschließlich auf der **Haupterhebung** ($N = 60$).

2.3 Datenerhebung

Die Datenerhebung erfolgte über die für wissenschaftliche Zwecke frei verfügbare Online-Befragungsplattform **SoSci Survey**. Für die Originalversion (GEB-50) und die entwickelte Kurzform wurden **zwei separate Fragebögen** erstellt, die über einen individuellen Prüfcode miteinander verknüpft werden konnten, sodass die Antworten jeder Person beiden Instrumenten zugeordnet werden können.

Das **GEB-50** umfasst 50 Items aus sechs Verhaltensdimensionen und besteht aus zwei Teilen: einem ersten Teil mit Antworten auf einer **sechsstufigen Likert-Skala** und einem zweiten Teil mit **dichotomen Items** (Antwortformat „Ja“/„Nein“). Die entwickelte **Kurzform (GEB-12)** umfasst zwölf dichotome Items („Ja“/„Nein“); aus jeder der sechs Dimensionen wurden zwei Items ausgewählt.

Die finale Datenerhebung erfolgte im Zeitraum vom **18.06. bis 28.06.2026**. Die Stichprobe setzte sich aus Mitstudierenden sowie Personen aus dem privaten Umfeld der Autor:innen zusammen und stellt somit eine **Gelegenheitsstichprobe** dar. Angestrebt wurde eine Stichprobengröße von mindestens $N = 50$; nach Ausschluss von Test- und Abbruchfällen umfasst die finale Auswertungsstichprobe $N = 60$ Personen (Kurz- und Langform jeweils 60).

Die Auswahl der zwölf Items für die Kurzform erfolgte **vorrangig auf theoretischer Grundlage**: Pro Handlungsbereich wurden zwei Items bestimmt – ein leichtes und ein schweres –, sodass die sechs Dimensionen vollständig und mit abgestufter Schwierigkeit abgebildet sind (siehe Kapitel 2.2 sowie die Konstruktionskriterien oben).

```
#### load data frames ####
Data_S_raw <- read.csv("Data_S.csv", header = TRUE, sep = ";",
                      check.names = FALSE, fileEncoding = "UCS-2LE")
Data_L_raw <- read.csv("Data_L.csv", header = TRUE, sep = ";",
                      check.names = FALSE, fileEncoding = "UCS-2LE")

# Select cases
Data_S_raw <- Data_S_raw[Data_S_raw$CASE != 28 & Data_S_raw$CASE != 29
                        & Data_S_raw$CASE != 30 & Data_S_raw$CASE != 31
                        & Data_S_raw$CASE != 42 & Data_S_raw$CASE != 94
                        & Data_S_raw$CASE != 111, ]

Data_L_raw <- Data_L_raw[Data_L_raw$CASE != 130 & Data_L_raw$CASE != 153
                        & Data_L_raw$CASE != 155 & Data_L_raw$CASE != 156
                        & Data_L_raw$CASE != 159 & Data_L_raw$CASE != 164
                        & Data_L_raw$CASE != 173 & Data_L_raw$CASE != 175
                        & Data_L_raw$CASE != 182 & Data_L_raw$CASE != 196
                        & Data_L_raw$CASE != 215 & Data_L_raw$CASE != 224
                        & Data_L_raw$CASE != 237, ]

## Short version (GEB-12)
# select colums
Data_S <- Data_S_raw %>% select(KG01_01, KG01_02, KG01_03, KG01_04, KG01_05,
                              KG01_06, KG01_07, KG01_08, KG01_09, KG01_10,
                              KG01_11, KG01_12)

# Recode
Data_S <- as.data.frame(sapply(Data_S[c(1:12)], car::recode, "-1=0; 2=0; 1=1"))

# Recode inverse items
Data_S[c(10)] <- as.data.frame(sapply(Data_S[c(10)], car::recode, "0=1; 1=0"))

## Long version (GEB-50)
Data_L <- unfactor(Data_L_raw[7:56])

# Inverse dichotomous items
Data_L[c(34,35,36,37,38,40)] <- as.data.frame(sapply(Data_L[c(34,35,36,37,38,40)],
                                                    car::recode, "1=2; 2=1"))

# Recode dichotomous items
Data_L[c(33:50)] <- as.data.frame(sapply(Data_L[c(33:50)], car::recode,
                                          "1=1; 2=0"))

# Inverse polytomous items
Data_L[c(3,4,6,7,10,17,18,23,26,27,28,29,31)] <- as.data.frame(
  sapply(Data_L[c(3,4,6,7,10,17,18,23,26,27,28,29,31)],
        car::recode, "1=5; 2=4; 3=3; 4=2; 5=1"))

# Dichotomize polytomous items
Data_L[c(1:32)] <- as.data.frame(sapply(Data_L[c(1:32)], car::recode,
                                          "1=0; 2=0; 3=0; 4=1; 5=1"))

# Data type -> numeric
i <- c(1:50)
Data_L[, i] <- apply(Data_L[, i], 2, function(x) as.numeric(as.character(x)))
```

2.4 Analyseplan

Der Bericht prüft die Kurzform parallel zur Langform mit Verfahren der klassischen Testtheorie (KTT) und der Item-Response-Theorie (IRT). Im Einzelnen: deskriptive Statistik (Mittelwert, SD, Median der Personenscores), drei Reliabilitätsschätzer – **Cronbachs** α , **McDonalds** ω (über die sechs Handlungsbereiche) und **Split-Half-Reliabilität** –, die **Spearman-Korrelation** der Summenscores von Kurz- und Langform, eine **konfirmatorische Faktorenanalyse** des Sechs-Bereiche-Modells (WLSMV-Schätzer für dichotome Items) sowie ein **dichotomes**

Tabelle 2: Itemkennwerte der GEB-12 (Schwierigkeit, Trennschärfe)

	Item	Schwierigkeit_P	Bewertung_P	Trennschaerfe_rit	Bewertung_rit
1	KG01_01	0.80	ok	0.16	kritisch
2	KG01_02	0.53	ok	0.19	kritisch
3	KG01_03	0.85	Decken/Boden	0.12	kritisch
4	KG01_04	0.57	ok	0.19	kritisch
5	KG01_05	0.83	Decken/Boden	0.12	kritisch
6	KG01_06	0.95	Decken/Boden	0.14	kritisch
7	KG01_07	0.63	ok	0.30	grenzwertig
8	KG01_08	0.52	ok	0.33	grenzwertig
9	KG01_09	0.93	Decken/Boden	0.04	kritisch
10	KG01_10-	0.10	Decken/Boden	0.04	kritisch
11	KG01_11	0.83	Decken/Boden	0.25	kritisch
12	KG01_12	0.15	Decken/Boden	0.36	grenzwertig

Rasch-Modell (eRm) mit Personenparametern und Separationsreliabilität. Als Zielkriterien gelten $\alpha/\omega \geq .70$, eine hohe Korrelation der Summenscores (Smith et al., 2000) sowie akzeptable CFA-Fitwerte (CFI > .95, RMSEA < .06, SRMR < .08). Fit-Indizes sind dabei nur aussagekräftig, wenn das Modell stabil identifiziert ist; bei Schätzproblemen (Nicht-Konvergenz, unzulässige Parameter) werden sie nicht inhaltlich interpretiert.

3 Ergebnisse (klassische Testtheorie)

3.1 Deskriptive Statistik

Zunächst werden Item- und Skalenkennwerte für Kurz- und Langform beschrieben. Tabelle 2 zeigt für jedes GEB-12-Item die Schwierigkeit P (Anteil zustimmender Antworten) und die part-whole-korrigierte Trennschärfe r_{it} , ergänzt um eine Einschätzung.

```
# Personen-Mittelwerte (Mittelwert, SD, Median) je Skala
Data_S_Mean <- rowMeans(Data_S, na.rm = TRUE)
Data_L_Mean <- rowMeans(Data_L, na.rm = TRUE)

psych::describe(Data_S_Mean) # GEB-12
```

```
vars  n mean  sd median trimmed mad min max range skew kurtosis se
X1    1 60 0.71 0.15  0.75  0.71 0.12 0.17  1  0.83 -0.53  1.05 0.02
```

```
psych::describe(Data_L_Mean) # GEB-50
```

```
vars  n mean  sd median trimmed mad min max range skew kurtosis se
X1    1 60 0.59 0.15  0.62  0.6 0.12 0.06 0.86  0.8 -0.92  1.21 0.02
```

3.2 Reliabilität: Alpha, Omega und Split-Half

Berichtet werden drei Reliabilitätsschätzer, jeweils für Kurz- und Langform.

```
#### Cronbachs Alpha ####
psych::alpha(Data_S, check.keys = TRUE) # GEB-12
psych::alpha(Data_L, check.keys = TRUE) # GEB-50

#### McDonalds Omega ueber die sechs Handlungsbereiche ####
psych::omega(Data_S, nfactors = 6, plot = FALSE) # GEB-12
psych::omega(Data_L, nfactors = 6, plot = FALSE) # GEB-50

#### Split-Half-Reliabilitaet ####
splitHalf(Data_S) # GEB-12
splitHalf(Data_L) # GEB-50
```

```
# A tibble: 2 x 4
  Skala Cronbachs_Alpha Omega_total Split_Half_mean
  <chr>      <dbl>      <dbl>      <dbl>
1 GEB-12 (Kurzform)      0.5        0.72        0.47
2 GEB-50 (Langform)      0.87        0.92        0.88
```

💡 Maßstab und Befund

Als Zielwert gilt $\alpha \geq .70$. Eine **Reduktion** gegenüber der Separationsreliabilität der Vollversion (.71–.88) wäre angesichts der starken Kürzung erwartbar und solange unkritisch, wie .70 erreicht wird. Tatsächlich verfehlt die GEB-12 dieses Kriterium mit $\alpha = .50$ (Split-Half .47) jedoch deutlich, während die Langform mit $\alpha = .87$ klar darüber liegt. Der Wert Omega total = .72 ist wegen Überparametrisierung (sechs Faktoren, zwölf Items) nicht belastbar.

3.3 Korrelation Kurzform vs. Langform

Das Kernkriterium der Konstruktvalidität nach Smith et al. (2000) ist die Übereinstimmung der Personenwerte beider Formen.

```
### Brava!s pearson correlation ###
Sum_L <- rowSums(Data_L, na.rm = TRUE) # GEB-50
Sum_S <- rowSums(Data_S, na.rm = TRUE) # GEB-12

# Spearman-Rangkorrelation
cor(Sum_L, Sum_S, method = "spearman")
```

```
[1] 0.2951678
```

```
# A tibble: 4 x 2
  Kennwert      Wert
  <chr>      <dbl>
1 N          60
2 Spearman-Rho (GEB-50 x GEB-12)  0.3
3 Mittelwert Summenscore GEB-50  29.5
4 Mittelwert Summenscore GEB-12   8.5
```

Eine hohe Korrelation würde belegen, dass die Kurzform die Personenordnung der Langform weitgehend reproduziert. Mit $\rho = .30$ besteht jedoch nur ein mittlerer Zusammenhang, der deutlich unter dem für eine valide Kurzform erwartbaren Niveau liegt. Dabei ist zu beachten, dass dieser Wert die Übereinstimmung sogar noch **überschätzt**: Die zwölf Items sind in der Langform enthalten (Item-Overlap), und die niedrige Reliabilität der Kurzform ($\alpha = .50$) deckelt die maximal erreichbare Korrelation rechnerisch nach oben – ein klassischer Effekt im Sinne von Smith et al. (2000).

4 Ergebnisse (Faktorstruktur und IRT)

4.1 Konfirmatorische Faktorenanalyse

Geprüft wird die faktorielle Struktur der GEB-12 über ein **Sechs-Faktoren-Modell**, das die sechs Handlungsbereiche als latente Faktoren mit je zwei Indikatoren abbildet. Da die Items dichotom sind, wird der Schätzer WLSMV mit Deklaration der Items als `ordered` verwendet.

```
#### CFA_Model ####
# Sechs-Faktoren-Modell (je Handlungsbereich ein Faktor mit 2 Items)
CFA_model <- '
Energiesparen =~ KG01_01 + KG01_02
Mobilität =~ KG01_03 + KG01_04
Abfallvermeiden =~ KG01_05 + KG01_06
Konsum =~ KG01_07 + KG01_08
```

```

Recycling =~ KG01_09 + KG01_10
Engagement =~ KG01_11 + KG01_12
,

lavaan::cfa(CFA_model, data = Data_S)

Items_S <- c("KG01_01", "KG01_02",
  "KG01_03", "KG01_04",
  "KG01_05", "KG01_06",
  "KG01_07", "KG01_08",
  "KG01_09", "KG01_10",
  "KG01_11", "KG01_12")

Fit <- cfa(CFA_model, data = Data_S,
  ordered = Items_S, estimator = "WLSMV")

summary(Fit, fit.measures = TRUE, standardized = TRUE)

```

chisq.scaled	df	pvalue.scaled	cfi.scaled	tli.scaled
28.933	39.000	0.881	1.000	1.473
rmsea.scaled	srmr			
0.000	0.134			

	lhs	rhs	est.std	pvalue
1	Energiesparen	KG01_01	0.611	0.016
2	Energiesparen	KG01_02	0.809	0.000
3	Mobilität	KG01_03	0.521	0.023
4	Mobilität	KG01_04	1.536	0.012
5	Abfallvermeiden	KG01_05	0.155	0.786
6	Abfallvermeiden	KG01_06	4.125	0.776
7	Konsum	KG01_07	0.711	0.000
8	Konsum	KG01_08	0.656	0.000
9	Recycling	KG01_09	0.966	0.033
10	Recycling	KG01_10	0.341	0.229
11	Engagement	KG01_11	0.449	0.036
12	Engagement	KG01_12	0.779	0.016

i Stichproben- und Identifikationsvorbehalt

Das Sechs-Faktoren-Modell hat Faktoren mit je nur **zwei Indikatoren**; solche Faktoren sind einzeln nicht identifiziert und nur über die Faktorkovarianzen schätzbar. In Kombination mit $N = 60$ und 12 dichotomen Items ist die CFA **schwach gepowert**: Schätzungen können Warnungen erzeugen, und die Fit-Indizes (CFI > .95, RMSEA < .06 als Zielwerte) sind mit Vorsicht zu interpretieren. Sie werden daher gemeinsam mit den Reliabilitäts- und Rasch-Ergebnissen bewertet.

4.2 Rasch-Modell (IRT)

Da die Langform rasch-skaliert ist, wird geprüft, ob die 12 Items das **dichotome Rasch-Modell** erfüllen → (Rasch, 1960). Geschätzt wird mit dem Paket **eRm** (konditionale Maximum-Likelihood).

```

#### Rasch model ####
# Rasch-Modell schätzen
Rasch <- RM(Data_S)
RM(Data_S)

# Itemparameter (Lokationen)

#### Person parameters ####
Person <- person.parameter(Rasch)
Person

# Personenparameter (theta)

#### Separation reliability ####
SepRel(Person)

```

```
# A tibble: 5 x 2
  Kennwert      Wert
  <chr>      <dbl>
1 N (effektiv, ohne Extremscores) 60
2 Anzahl Items      12
3 Itemschwierigkeit Beta min    -1.98
4 Itemschwierigkeit Beta max     3.2
5 Separationsreliabilität      0.42
```

i Befund und Stichprobe

Die Separationsreliabilität beträgt nur .42: Das Modell trennt die Personen also schwach, was das Bild der niedrigen internen Konsistenz bestätigt. Die Itemschwierigkeiten streuen zwar breit (von $\beta = -1.98$ bis $\beta = 3.20$), die geringe Separation bleibt davon jedoch unberührt. Generell sind bei $N = 60$ und 12 Items die CML-Schätzungen mit breiten Konfidenzintervallen behaftet.

5 Diskussion

5.1 Ist die GEB-12 eine gute Kurzform?

Die Bewertung folgt den Zielkriterien aus dem Analyseplan. Im Ergebnis **verfehlt die GEB-12 die psychometrischen Zielkriterien deutlich**, während die Langform GEB-50 ihre Gütekriterien klar erfüllt. Die einzelnen Befunde:

- **Interne Konsistenz:** Die Langform erreicht ein Cronbachs $\alpha = .87$ (Split-Half .88, Omega total .92) und misst die Umwelteinstellung intern konsistent. Die Kurzform bleibt mit $\alpha = .50$ und einer durchschnittlichen Split-Half-Reliabilität von .47 klar unter dem Zielwert .70. Der zunächst akzeptabel wirkende Wert von Omega total = .72 ist nicht belastbar: Bei zwölf Items auf sechs Faktoren ist das Omega-Modell überparametrisiert (Omega hierarchical nur .34), sodass dieser Wert die tatsächliche Reliabilität überschätzt.
- **Korrelation Kurz-/Langform:** Die Summenscores korrelieren nur zu $\rho = .30$ (Spearman) - ein lediglich mittlerer Zusammenhang. Für eine valide Kurzform wäre ein deutlich höherer Wert zu erwarten (Smith et al., 2000). Die GEB-12 reproduziert die Personenordnung der Langform also nur eingeschränkt.
- **Faktorstruktur:** Die scheinbar perfekten Fit-Indizes (CFI = 1.00, RMSEA = .00) sind vermutlich **Artefakte eines nicht stabil identifizierten Modells**: Bereits der erste, ungerichtete CFA-Aufruf konvergierte nicht, und die WLSMV-Lösung weist unzulässige Schätzwerte auf (eine standardisierte Faktorladung > 1 bei KG01_06 sowie negative Residualvarianzen). Der einzige hier belastbare Fit-Index ist der SRMR = .13 welcher über dem Grenzwert von .08 liegt. Die CFA bestätigt die Sechs-Faktoren-Struktur somit **nicht**.
- **Rasch-Modell:** Die Separationsreliabilität beträgt .42; das Modell trennt die Personen also unzureichend. Die Itemschwierigkeiten streuen breit (von $\beta = -1.98$ für KG01_06 bis $\beta = 3.20$ für KG01_12). Dies spiegelt die beabsichtigte Mischung leichter und schwerer Items, jedoch bestätigt die geringe Separation das Bild der niedrigen internen Konsistenz.

Eine Ursache zeigt sich in der Itemanalyse (siehe Tabelle 2): Die meisten GEB-12-Items haben **Trennschärfen unter .30** (kritisch); nur KG01_07, KG01_08 und KG01_12 erreichen grenzwertige Werte um .30–.36. Zudem liegen mehrere Items im Decken- bzw. Bodenbereich (z. B. KG01_06 mit $P = .95$, KG01_12 mit $P = .15$). Niedrige Trennschärfen senken unmittelbar die Reliabilität. Dies erklärt das niedrige α und die schwache Rasch-Trennung.

In ihrer jetzigen Form ist die GEB-12 **keine ausreichend reliable und valide Kurzform** der GEB-50. Dieser Befund ist jedoch gut erklärbar und methodisch lehrreich: Die hohe Güte der Langform ($\alpha = .87$) zeigt, dass das Ausgangsinstrument solide ist. Das Problem liegt also nicht im generellen Konstrukt, sondern in der **Kürzung**. Eine bewusst über sechs heterogene Handlungsbereiche gestreute Auswahl von nur zwei Items pro Bereich maximiert zwar die inhaltliche Breite, minimiert aber zwangsläufig die Inter-Item-Korrelationen (durchschnittlich nur .07) sowie die interne Konsistenz. Genau dies ist eine der von Smith et al. (2000) beschriebenen Spannungen der Kurzformentwicklung: Breite und interne Konsistenz lassen sich bei extremer Kürzung nicht gleichzeitig maximieren.

Für eine Weiterentwicklung ergeben sich hier konkrete Ansatzpunkte: Items mit sehr niedriger Trennschärfe oder extremer Schwierigkeit (etwa KG01_06 und KG01_09) könnten gegen trennschärfere Items desselben Bereichs ausgetauscht, die Itemzahl pro Bereich moderat erhöht oder es könnte auf eine einzelne Reliabilitätskennzahl als

Hauptkriterium verzichtet werden, zugunsten einer explizit mehrdimensionalen Konzeption. Eine größere und heterogenere Stichprobe würde zudem stabilere CFA- und Rasch-Schätzungen ermöglichen.

5.2 Einschränkungen

Die wichtigste Einschränkung ist der **Stichprobenumfang** ($N = 60$). Er erlaubt orientierende KTT-Kennwerte, ist für CFA und IRT mit 12 dichotomen Items aber klein. Die Fit- und Itemparameter sind entsprechend unsicher. Aus demselben Grund konnte der vorgeschaltete Pretest mit $N = 6$ nur die Verständlichkeit und Durchführbarkeit absichern und keine belastbare Itemselektion leisten (siehe Kapitel 2.2).

Eine weitere Einschränkung betrifft den **Umgang mit fehlenden Werten**: Zur Vereinfachung der Auswertung wurde die explizite *Keine-Angabe*-Option (NA) nicht gesondert modelliert, sondern im Recoding mit „trifft nicht zu“ (0) zusammengefasst. Dies kann die Antwortverteilung verzerren, da eine bewusste Enthaltung nicht dasselbe ist wie eine Verneinung des Verhaltens. Diese Vereinfachung wurde im Vorfeld nicht ausreichend bedacht und sollte in einer Folgerhebung sauber getrennt behandelt werden.

Schließlich handelt es sich um eine **Gelegenheitsstichprobe**, die sich überwiegend aus Studierenden sowie Personen aus dem privaten Umfeld der Autor:innen zusammensetzt. Sie ist damit nicht repräsentativ für die Allgemeinbevölkerung; die Ergebnisse sind als **Machbarkeitsnachweis** der theoriegeleiteten Kurzform zu verstehen, nicht als abschließende Validierung.

6 Literatur

- Kaiser, F. G. (2020). *GEB-50. General Ecological Behavior Scale [Verfahrensdokumentation]*. In ZPID (Hrsg.), Open Test Archive. Trier: ZPID. <https://doi.org/10.23668/psycharchives.4489>
- Rasch, G. (1960). *Probabilistic Models for Some Intelligence and Attainment Tests*. Danmarks Paedagogiske Institut.
- Smith, G. T., McCarthy, D. M., & Anderson, K. G. (2000). On the sins of short-form development. *Psychological Assessment*, 12(1), 102–111. <https://doi.org/10.1037/1040-3590.12.1.102>